

审稿意见：Q-learning Based Adaptive Control of UAVs for High-precision Expressway Service Area Mapping

期刊：Drones (MDPI)

审稿人角色：无人机飞行控制 & 强化学习领域专家

总体评价：大修 (Major Revision)

一、总体评价

本文将Q-learning与三维锥螺旋导航控制结合，用于高速公路服务区高精度测绘场景下固定翼无人机的轨迹跟踪。选题有实际工程意义，实验结果展示了相对于固定增益控制器的显著改进。然而，论文在方法创新性论证、实验设计严谨性、与现有方法的对比深度、以及写作质量方面存在较多不足，需要进行系统性修改。

二、关键性问题（必须解决）

2.1 创新性论证不足

问题：Q-learning是最基础的表格型强化学习算法，状态空间仅3个离散状态（L/M/R），动作空间仅3个（D/U/I）。这是一个极其简单的9格Q表。论文需要说服审稿人：为何这个简单方案足够，且构成有意义的学术贡献。

修改建议：

- 在Introduction中明确论述：为何在该特定应用场景下，tabular Q-learning优于更复杂的DRL方法（如DDPG、PPO）。需要从实时性、可解释性、安全可验证性、嵌入式部署等角度进行有理有据的论证，而不是简单回避。
- 增加一段与DRL方法的定性/定量对比讨论，说明在3×3状态-动作空间下tabular方法的收敛保证和计算优势。
- 考虑补充实验：用DDPG或DQN作为对比基线，证明简单Q-learning在此场景下已够用或更优。

2.2 Baseline选择过弱

问题：唯一的对比基线是“fixed-gain controller”，但从Table 4看，该baseline的MAE高达8.22m，100%的采样点都不在5m误差范围内。这个baseline性能极差，几乎任何自适应方法都能大幅超越它。

修改建议：

- 至少增加以下对比方法中的2-3个：
 - **PID自适应控制器**（如增益调度PID）
 - **L1自适应控制**（论文引言中已提及L1-Navigation）
 - **LQR控制器**（论文引言中已提及）
 - **简单规则基础的增益调整**（如基于误差阈值的分段增益切换）
- 如果baseline的8m误差是由于参数整定不当，需要说明该baseline已经经过合理调参，否则对比不公平。

2.3 仅有仿真验证，无实飞数据

问题：全部实验在ArduPilot SITL中完成。论文标题和摘要使用“Flight tests”等措辞容易误导。对于Drones期刊，纯仿真论文的录用门槛更高。

修改建议：

- **最佳方案**：补充实际飞行测试数据，哪怕只有一组实飞结果也会大幅提升论文说服力。
- **次优方案**：如果无法实飞，需要：
 - 将所有“flight test”措辞修改为“simulation experiment”或“SITL simulation”
 - 在Discussion中诚实讨论sim-to-real gap，包括传感器噪声、执行器延迟、真实风场的非平稳性等
 - 增加更逼真的仿真条件：如湍流模型（Dryden/von Karman）、传感器噪声注入、通信延迟等

2.4 状态空间设计缺乏理论依据

问题：将连续轨迹误差离散化为仅3个状态（L/M/R），阈值如何确定？为何是3个而不是5个或7个？这直接影响控制精度。

修改建议：

- 明确给出L/M/R的量化阈值定义（如 $|d_l| < -\epsilon$ 为L， $|d_l| \leq \epsilon$ 为M， $|d_l| > \epsilon$ 为R），并说明 ϵ 的选取依据。

- 进行状态空间粒度的消融实验 (ablation study)：对比3/5/7/9个状态划分下的跟踪精度，论证当前设计的合理性。
- 讨论粗粒度离散化的局限性：当误差在阈值附近时，控制行为可能出现chattering。

2.5 奖励函数设计过于粗糙

问题：公式(28)的奖励函数仅有三个离散值{100, 0, -1}，且正奖励(100)与负奖励(-1)之间严重不对称，缺乏理论动机。中间值“0, e_{tl} ”的含义也不清楚。

修改建议：

- 解释100 vs -1不对称设计的理由，或改用更合理的奖励设计。
- 明确 e_{tl} 的定义和取值条件——当前公式(28)中间行“0, e_{tl} ”语义模糊。
- 讨论奖励shaping的影响：是否尝试过连续奖励（如 $R = -|e_r|$ ）？为何选择当前的稀疏奖励？
- 进行奖励函数消融实验：对比不同奖励设计对收敛速度和最终性能的影响。

三、方法论问题

3.1 离线训练的数据来源与泛化性

- 离线训练使用21组飞行数据（1个无风 + 5风速×4风向）。但实际部署时风场是连续变化的、且包含湍流分量。如何保证Q表对训练集外的风场条件泛化？
- 建议增加对未训练过的风速（如3m/s, 7m/s）和风向（如45°, 135°）的泛化性测试。

3.2 Q-learning收敛性分析不充分

- 论文声称500-600个episode收敛，但未给出收敛曲线图。
- 必须添加：Q值随episode变化的收敛曲线图，以及累积奖励的学习曲线。
- 讨论学习率 α 和折扣因子 γ 的具体取值及其对收敛的影响。

3.3 公式(21)的增益调整机制不清

- 公式(21)中 K_r 和 K_v 是增益系数，Q-learning的动作是对 k_l 进行增/减/保持。但 k_l 是曲率，与 K_r/K_v 的关系是什么？
- 增益调整的步长（每次增加/减少多少）是如何确定的？这个关键实现细节缺失。
- 需要明确说明Q-learning输出如何映射到具体的控制参数变化量。

3.4 缺少计算量与实时性分析

- 虽然提到训练约3秒，但未讨论在线推理的计算开销。
 - 对于固定翼UAV的控制频率（通常50-400Hz），Q表查询是否满足实时性？
 - 建议给出控制回路频率和单步决策耗时。
-

四、实验设计问题

4.1 统计显著性不足

- 表4和图7的对比仅基于单次飞行。即使Section 4.3做了多初始角度测试，也仅报告了均值和标准差，未做统计检验。
- 建议：对每个条件运行至少10次独立实验（含不同随机种子），报告均值 $\pm$ 标准差，并进行t检验或Wilcoxon检验。

4.2 缺少关键消融实验

需补充的消融实验包括：

1. 状态空间粒度（3 vs 5 vs 7状态）
2. 奖励函数设计（稀疏 vs 连续奖励）
3. 动作步长大小的影响
4. ϵ -greedy中 ϵ 衰减策略的影响
5. 训练episode数量对最终性能的影响

4.3 高度方向跟踪精度缺失

- 论文动机是减少“image pixel elevation discrepancies”，但所有误差指标均为径向误差 d_r ，未单独报告高度方向的跟踪误差。
- 必须补充：高度跟踪误差的统计量（MAE、RMSE），这直接关系到测绘质量。

4.4 缺少与测绘质量的直接关联

- 论文声称改善测绘精度，但未给出任何测绘质量指标（如正射影像分辨率、DEM精度、GSD一致性）。
- 至少应建立轨迹跟踪精度与GSD（Ground Sampling Distance）变化之间的定量关系模型，说明0.55m的MAE对应多少GSD改善。

五、写作与表达问题

5.1 英语语言质量

论文存在大量语法和表述问题，需要全面润色：

- “fix-wing” → “fixed-wing”（全文多处）
- “the intelligence remembers the value function” → 不当拟人化，建议 “the value function under policy π is defined as”
- 公式(28)中间行 “0, e_{tl} ” 含义不明
- Section 3.1标题为”Q Learning algorithm principle”但编号为3.1，而Section 3上方的3.2（3D CSNFL）内容在Section 2中——章节编号混乱
- 引用格式不统一：有的用[1]，有的用[1, 2]，有的用[3-5]
- 多处缺少标点和空格（如 “[2, 3]”前无空格）
- Table 4标题 “This is a table The performance metrics” 明显是草稿遗留
- “Firstname Lastname” 作为Academic Editor未替换

5.2 章节结构问题

- Section 3的标题暗示要讲Q-learning设计，但3.1才是Q-learning原理，中间缺少3.2的编号（直接跳到了3.3）。
- Section 2.2已经介绍了3D CSNFL算法，但Section 3中又重新引用了公式(21)。建议重组，将导航控制模型和Q-learning设计分别清晰地放在独立章节。
- 建议增加一个系统架构总览图，展示离线训练-在线控制的完整pipeline。

5.3 图表质量

- Figure 1的标注文字不清晰，部分标注被遮挡。
 - Figure 5和Figure 6的图例放置应统一。
 - 建议将Table 3的Q表与对应的物理含义一起解释（如”当状态为M时，最优动作是U（保持增益），Q值最高497.10”）。
 - 所有图的字体需统一且足够大，建议不小于10pt。
-

六、文献综述改进

6.1 缺少关键对比文献

- 未引用自适应PID在UAV中的应用（这是最直接的竞争方法）
- 未引用model predictive control (MPC)用于UAV轨迹跟踪的经典工作
- 未引用Q-learning用于机器人/无人机控制的先驱工作（如Kober et al., 2013的RL survey）
- 引言中列举了DDPG、DRL等方法，但未讨论为何不直接使用这些方法

6.2 引用质量问题

- 参考文献中有多篇2025年的arXiv预印本（[18][19][20]），部分与论文主题关联度低（如[19]是aerial-ground collaboration driving dataset，与本文几乎无关）。
 - 建议替换为该领域更经典、已发表的期刊/会议论文。
 - 参考文献[23]关于UAV测量精度评估，被用于支撑收敛性分析的描述，但该引用内容与收敛性分析无关。
-

七、具体技术建议

7.1 方法扩展方向（可选但推荐）

1. 连续动作空间：考虑将离散的增/减/保持扩展为连续的增益调整量，使用函数逼近（如线性Q-learning或简单的Actor-Critic），可显著提升精细控制能力。
2. 多目标优化：在奖励函数中同时考虑轨迹跟踪精度和能量消耗。
3. 在线学习：当前方案是offline training + online inference。考虑加入online fine-tuning机制以适应实时环境变化。

7.2 补充可视化

- 增加Q值收敛曲线
 - 增加增益系数 K 随飞行进程的变化曲线（展示Q-learning如何动态调整增益）
 - 增加高度跟踪误差曲线
 - 增加风扰动下的误差概率分布直方图或箱线图
-

八、修改优先级总结

优先级	修改内容	重要程度
P0	增加更强的baseline对比（PID自适应/LQR/L1）	★★★★★
P0	补充高度方向跟踪误差指标	★★★★★
P0	明确状态离散化阈值并做消融实验	★★★★★
P0	修复写作问题（语法、编号、草稿痕迹）	★★★★★
P1	补充Q值收敛曲线和增益变化曲线	★★★★
P1	增加DRL方法（DDPG/PPO）对比或充分论证为何不需要	★★★★
P1	奖励函数设计解释与消融	★★★★
P1	增益调整步长和控制映射机制的清晰说明	★★★★
P2	泛化性测试（未训练风场条件）	★★★
P2	实飞验证或更逼真仿真条件	★★★
P2	轨迹精度与测绘质量GSD的定量关联	★★★
P3	文献综述补充与引用质量提升	★★
P3	方法扩展讨论（连续动作空间等）	★★

九、审稿结论

本文选题方向具有实用价值，Q-learning与锥螺旋导航的结合思路有一定新意。但当前版本在**基线对比的公平性、方法设计的理论深度、实验的全面性和统计严谨性**方面存在明显不足。建议作者按上述意见进行大修后重新提交。如果能补充更强的baseline对比、消融实验、收敛分析图、以及高度方向误差指标，论文质量将有质的提升。

审稿日期：2026年4月9日